

Análisis Topológico de Señales Biomédicas

Motor de Procesamiento y Reconstrucción de Atractores EEG

Rosh Guadiana P. - Lourdes M. García G. - Bárbara del R. Almazán B. - Edwin Montes O. - Osiris Díaz Torres


12 de mayo de 2026

Biomédica y Topología

El Desafío: ¿Qué estamos midiendo?

- El cerebro es un sistema dinámico gobernado por un flujo ϕ^t sobre una variedad compacta $\mathcal{M}$ de **alta dimensión** d .
- El EEG es solo una **función de observación** escalar unidimensional $y : \mathcal{M} \rightarrow \mathbb{R}$, dando la serie $x(t) = y(\phi^t(s_0))$.
- **Reto:** ¿Cómo recuperar la dinámica invariante topológica de la red neuronal desde una sola observación temporal?

Observación 1D $x(t)$



Atractor Multidimensional

Concepto 1: El Estado y el Espacio de Fase

- **Estado:** El vector $\mathbf{x}(t) \in \mathbb{R}^n$ que define unívocamente las condiciones iniciales del sistema.
- **Espacio de Fase:** La variedad diferenciable donde coexisten todas las trayectorias $\mathbf{x}(t)$ admisibles.

La evolución geométrica es dictada por el sistema dinámico continuo:

$$\frac{d\mathbf{x}}{dt} = F(\mathbf{x}(t), \mu)$$



Concepto 2: Variedades Diferenciables ($\mathcal{M}$)

¿Por qué modelamos el cerebro como una variedad?

- Es un espacio topológico Hausdorff, **localmente homeomorfo** a $\mathbb{R}^d$.
- Está equipado con una estructura de atlas suave (C^∞), permitiendo el cálculo diferencial mediante las cartas locales:

Cartas y Transiciones

$$\psi_\alpha : U_\alpha \subset \mathcal{M} \rightarrow \mathbb{R}^d$$

Los mapas de transición $\psi_\beta \circ \psi_\alpha^{-1}$ son difeomorfismos suaves que preservan la estructura del espacio.

Concepto 3: Difeomorfismos e Invariantes

Equivalencia Topológica ($\cong$)

Dos espacios son homeomorfos si existe una biyección continua con inversa continua.

Un **difeomorfismo** $h : \mathcal{M} \rightarrow \mathcal{N}$ requiere además que h y h^{-1} sean suaves.

Esto asegura la preservación de los **invariantes dinámicos** subyacentes, como los exponentes característicos de Lyapunov λ_i y la dimensión fractal de correlación D_2 .



homeomorphism.png

Variedad $A \cong$ Variedad B

La Solución: Teorema de Inmersión de Takens (1981)

Sea $\mathcal{M}$ una variedad compacta de dimensión d . Para un par genérico (ϕ, y) , donde $\phi : \mathcal{M} \rightarrow \mathcal{M}$ es un difeomorfismo suave y $y : \mathcal{M} \rightarrow \mathbb{R}$ es una función de observación, el mapa de inmersión por retrasos $\Phi_{\tau, m} : \mathcal{M} \rightarrow \mathbb{R}^m$ dado por:

Mapeo de Reconstrucción

$$\Phi_{\tau, m}(x) = \begin{bmatrix} y(x) \\ y(\phi^\tau(x)) \\ y(\phi^{2\tau}(x)) \\ \vdots \\ y(\phi^{(m-1)\tau}(x)) \end{bmatrix} \equiv \mathbf{X}(t)$$


$m \geq 2d + 1$ Condición de incrustación de Whitney para garantizar inyectividad diferencial (ausencia de auto-intersecciones espurias).

τ Retraso temporal (Tau).

¿Cómo elegir τ ? (Independencia Estadística)

Maximizamos la ortogonalidad topológica usando la **Información Mutua (MI)** para dependencias no lineales, o el Teorema de Wiener-Khinchin para las lineales:

$$I(\tau) = \sum_{x(t), x(t+\tau)} P(x(t), x(t+\tau)) \log_2 \left(\frac{P(x(t), x(t+\tau))}{P(x(t))P(x(t+\tau))} \right)$$



Buscamos el primer mínimo de $I(\tau)$ para asegurar que $\mathbf{X}(t)$ expanda eficientemente el espacio de fase.

Ingeniería: Eficiencia con Stride Tricks

Evitamos copiar gigabytes de datos en RAM (Complejidad $\mathcal{O}(1)$ en espacio). Transformamos el tensor mapeando la **Matriz de Hankel** controlando la aritmética de punteros a nivel del CPU.

```
import numpy as np

def embed_signal(x, m, tau):
    """Inmersi3n topol3gica  $\mathcal{O}(1)$  usando 3lgebra tensorial en NumPy"""
    shape = (x.shape[0] - (m - 1) * tau, m)
    strides = (x.strides[0], x.strides[0] * tau)

    # Vista en memoria isom3rfica al atractor, sin duplicaci3n
    return np.lib.stride_tricks.as_strided(x, shape, strides)
```


Fusión de Geometría y Frecuencia

Asignamos energía espectral instantánea como un gradiente continuo sobre la variedad 3D reconstruida, utilizando la **Transformada Continua de Wavelet (CWT)**.

$$W_x(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} x(t) \bar{\psi} \left(\frac{t - b}{a} \right) dt$$

$$E_{loc}(t) = \int_{a_1}^{a_2} |W_x(a, t)|^2 \frac{da}{a^2}$$

Intersección entre el dominio tiempo-escala y el análisis topológico no lineal.

wavelet.png

Vigilia Activa Atractor extraño, espectro de Lyapunov positivo $\lambda_1 > 0$ (caos determinista) y alta entropía métrica. La red procesa información de forma altamente paralela.

Sueño Profundo / Coma Bifurcación topológica hacia múltiples *ciclos límite*. La corteza está sincronizada por el tálamo restringiendo sus grados de libertad.

Crisis Epiléptica Contracción drástica de la dimensionalidad de inmersión (hipersincronía patológica). Transformación abrupta en el espacio de fase que antecede la crisis.

Cuantificación: Persistencia de Dinámica Larga

El **Exponente de Hurst** (H) extraído del análisis de Rango Reescalado parametriza las correlaciones asintóticas espaciotemporales de la red:

$$\mathbb{E} \left[\frac{R(n)}{S(n)} \right] \sim Cn^H \quad \text{cuando } n \rightarrow \infty$$

- $H > 0,5$ **Persistente**. Memoria a largo plazo, dinámica cerebral sana y acoplamiento robusto (ruido fraccionario).
- $H \approx 0,5$ **Ruido Blanco**. Ausencia de correlaciones de largo alcance (movimiento Browniano puro).
- $H < 0,5$ **Anti-persistente**. Ruido violeta; alta volatilidad neural y reversión rápida a la media estructural.

Demo

Referencias Bibliográficas i

Teoría Fundamental

- Takens, F. (1981). *Detecting strange attractors in turbulence*. Lecture Notes in Mathematics, 898, 366-381. Springer, Berlin.
- Sauer, T., Yorke, J. A., & Casdagli, M. (1991). *Embedology*. Journal of Statistical Physics, 65(3-4), 579-616.
- Fraser, A. M., & Swinney, H. L. (1986). *Independent coordinates for strange attractors from mutual information*. Physical Review A, 33(2), 1134-1140.
- Cao, L. (1997). *Practical method for determining the minimum embedding dimension of a scalar time series*. Physica D: Nonlinear Phenomena, 110(1-2), 43-50.

Dinámica No Lineal en EEG

- Babloyantz, A., Salazar, J. M., & Nicolis, C. (1985). *Evidence of chaotic dynamics of brain activity during the sleep cycle*. Physics Letters A, 111(3), 152-156.
- Le Van Quyen, M., et al. (2001). *Anticipation of epileptic seizures from standard EEG recordings*. The Lancet, 357(9251), 183-188.
- Stam, C. J., et al. (1999). *Investigation of EEG non-linearity in dementia and Parkinson's disease*. Electroencephalography and Clinical Neurophysiology, 95(5), 309-317.
- Linkenkaer-Hansen, K., et al. (2001). *Long-range temporal correlations and scaling behavior in human brain oscillations*. Journal of Neuroscience, 21(4), 1370-1377.

Métodos de Procesamiento de Señales

- Welch, P. D. (1967). *The use of fast Fourier transform for the estimation of power spectra*. IEEE Transactions on Audio and Electroacoustics, 15(2), 70-73.
- Grossmann, A., & Morlet, J. (1984). *Decomposition of Hardy functions into square integrable wavelets of constant shape*. SIAM Journal on Mathematical Analysis, 15(4), 723-736.
- Hurst, H. E. (1951). *Long-term storage capacity of reservoirs*. Transactions of the American Society of Civil Engineers, 116, 770-799.

Bibliotecas y Software Médico

- Gramfort, A. et al. (2013). *MEG and EEG data analysis with MNE-Python*. Frontiers in Neuroscience, 7, 267.
- Niedermeyer, E., & Lopes da Silva, F. H. (2011). *Electroencephalography: Basic Principles, Clinical Applications, and Related Fields*. 6th ed. Lippincott Williams & Wilkins.